Цепочка мозговой ветки: от B266 до конца — план по кирпичику

Парный документ к `AUDIT_CLAUDE_B266_35_6_1_RU.md`

---

0. Принцип этого документа

Ваш собственный проект уже написал **два** серьёзных внутренних плана: `AUDIT_..._BRAIN_FULL_..._ORIGINAL.md` (BUILD 1→20, % прогресса по 12 измерениям) и `docs/brain/BRAIN_MASTER_PLAN_AND_AUDIT...` (B-M0→B-M18, L0-L9 анатомические слои). Я их прочитал полностью. Я **не переписываю их заново** — это была бы работа хуже, чем то, что уже есть. Вместо этого я:

1. Свожу оба плана в одну согласованную линию (они частично разошлись — реальное исполнение B259-B266 пошло не буквально по BUILD-списку, а адаптивно, что нормально, но нигде явно не сверено между собой).
2. Даю **конкретные следующие кирпичи**, начиная ровно с того места, где вы сейчас находитесь (после B266, архив датирован 2026-09-12).
3. Добавляю **свои методы**, которых нет ни в одном из ваших документов, там, где я вижу реальный пробел.
4. Применяю ваше правило: если шаг улучшает одно и ухудшает другое — ищу альтернативу, кроме случаев явного большого выигрыша при потере в пределах нескольких процентов.
5. Организую шаги крупными «проходами» (big pass), как вы просили, а не мелкой нарезкой.

---

1. Сверка двух ваших планов — что означает "после B266"

`ORIGINAL`-документ предполагал: B262=action/basal-ganglia/cerebellum loop, B263=self-model, B264=agency, B265=motivation, B266=sleep/replay. Реально случилось иначе: B262=multi-timescale world dynamics, B263=real action causality, B264=causal policy, B265=independent evaluator, B266=hidden-task generalization. **Это хороший знак, не плохой** — план адаптировался к тому, что реально оказалось нужным по ходу (после B262

стало ясно, что мир предсказывается, но планировщик не работает — план скорректировался в сторону причинности и независимой оценки раньше, чем в сторону self-model/motivation). Но это означает, что **self-model as learned dynamics, agency as causal inference, motivation/value formation, sleep/replay consolidation** — всё то, что `ORIGINAL` планировал под номерами 263-266 — **всё ещё не сделано** под этими именами. Это не потерялось — это просто сдвинулось вперёд по очереди.

Используя обе шкалы прогресса (`ORIGINAL` §33 + B266 §10 + мой синтез), вот где вы находитесь по состоянию на архив B266:

Измерение	**% (сведено из обоих ваших документов + моя проверка)**
Architecture completion	~82%
Runtime engineering	~78%
Evidence infrastructure	~74%
Cognitive architecture breadth	~86%
Learned neural depth	~36% (не изменилось принципиально за B259-266 — это то самое застревание)
Closed-loop embodiment	~42%
Continual developmental learning	~46%
Autonomous motivation depth	~31%
Functional self/identity	~64%
Consciousness evidence	~8%
Автономный запуск без внешнего триггера (моя проверка)	**~15%** ← новое, критичное
Brain branch engineering readiness	~84-86%

---

2. Синтез двух диагнозов «застревания» — они об одном и том же

Ваш собственный `ORIGINAL`-документ (§4) называет паттерн: новый brain-концепт → отдельный TS-модуль → state → clamp+weighted formula → synthetic test → snapshot/restore → интегратор перемножает

коэффициенты → pass отмечен verified → появляется следующий модуль. Он даже называет конкретные жертвы этого паттерна: `SparsePredictiveGraph` (B250, не настоящий learned sparse graph), `LocalNeuralCreditAssigner` (B251, credit score без реального распределения по параметрам), `MetaMemoryController` (B252, метрики без реального differentiable-контроллера), `SandboxedSelfRewriteEngine` (B253, safety-gate, а не self-development engine), `SensorimotorCoSimulationEngine` (B254, transfer evaluator, а не полноценная sensorimotor world model), `HybridCausalPlasticityCompiler` (B258, хороший gate, но не deep plasticity).

Мой собственный независимый синтез (аудит-документ, раздел 3) нашёл другую грань той же проблемы на более позднем участке (B262–266): каждый новый причинный слой добавляет **измерение** проблемы (`planningAdvantage01`, `behavioralGain01`, `causalGain01`…), но не решает первопричину — недостаток разнообразных, реально различимых последствий действий.

Это одна и та же болезнь, увиденная в двух разных временных срезах: и до B259, и после B266 — рост числа модулей/метрик опережает рост реального обучаемого поведения. Ваш собственный `ORIGINAL`-документ уже дал верный рецепт в §34: *«Самый ценный шаг — не ещё один мозговой орган. Самый ценный шаг — сделать так, чтобы уже созданные органы действительно учились вместе»*. Это полностью совпадает с моим собственным независимым выводом. Две независимые диагностики, сошедшиеся в одной точке — это сильный сигнал, что диагноз верный, а не случайное совпадение мнений.

---

3. КИРПИЧ 0 (немедленно, до всего остального): ПОЧИНИТЬ `autoRun`

Это не часть «мозговой» науки — это чистая инженерия, но она блокирует буквально саму возможность автономности, которую вся brain-ветка пытается доказать. Нашёл я, не было в ваших документах.

Диагноз (полный технический разбор — в аудит-документе, раздел 2.1): условие `run: cognitiveBudget01 >= 0.45 && awake` внутри `decide()` таймера `'cognitive'` не выполняется на свежесозданном организме — поэтому таймер планируется, но реальный тик не исполняется.

Что делать (2 совместимых варианта, не взаимоисключающих):

1. **Немедленный, минимальный фикс:** проверить дефолтные значения `cognitiveBudget01` и `embodiment.snapshot().awake` при

`init()` свежего организма. Если это осознанный дизайн («организм спит, пока его не разбудят явно») — тогда `autoRun: true` должен либо сам вызывать «пробуждение» при старте, либо тест должен явно разбудить организм перед проверкой autoRun, а не полагаться на дефолт. Если это НЕ осознанный дизайн, а просто нигде не инициализированный порог — поднять/скорректировать дефолт так, чтобы свежий организм проходил гейт хотя бы на минимальном «эко»-уровне бюджета.

2. **Более глубокое, научно интереснее решение (моя рекомендация, заимствование из SOAR — см. аудит §6.2):** вместо тихого пропуска цикла при недостаточном бюджете, реализовать **impasse-driven subgoal**: когда `cognitiveBudget01 < 0.45`, вместо `run: false` организм должен **сгенерировать явную внутреннюю подцель** «понять/восстановить причину нехватки ресурса» и **эта** более лёгкая подцель выполняется вместо полного цикла. Так автономность сохраняется всегда (тик всегда что-то делает), просто разная «глубина» доступна в разных состояниях — вместо бинарного работает/не работает. Это чинит баг и одновременно даёт организму осмысленное «низкоресурсное самонаблюдение» вместо тишины.

Критерий готовности: `npm run test:p15.5` (и, в идеале, весь `npm run audit:all` до конца, без остановки на первой ошибке) проходит зелёным трижды подряд без ручного вмешательства.

Почему это КИРПИЧ 0, а не часть общей очереди: любой последующий большой шаг (B267 и далее) явно нацелен на «сделать обнаружение сдвига мира и адаптацию частью самой ЖИВОЙ cognitive loop, а не только benchmark» (ваши же слова, B266 §12). Если живой цикл физически не тикает сам по себе — весь смысл «живого» B267 подрывается в фундаменте.

---

4. КИРПИЧ 1 (следующий большой проход): B267, обогащённый

Ваш собственный B266-аудит уже спроектировал B267 хорошо (regime-shift detector, калиброванная неопределённость, active verification, explore/exploit switch, lifelong task-family expansion, post-shift recovery benchmark, no-self-report-bias rule, независимый evaluator регенерируется после адаптации). Я это подтверждаю как правильный следующий шаг — не предлагаю замену. Добавляю три вещи:

4.1 Явная проверка «это не седьмой модуль в повторяющемся цикле»

Перед тем, как отмечать B267 как VERIFIED, явно прогнать через **Neural Reality Gate** из вашего же `ORIGINAL`-документа (§14) — A) эффект возникает из реального input? B) исчезает при lesion? C) сохраняется после restart/replay? D) переносится на unseen context? Если хотя бы один пункт не пройден по-настоящему (не «есть тест», а «эффект измеримо соответствует пункту») — B267 не считается закрытым, сколько бы кода ни было написано.

4.2 Curiosity-Gated Action Diversification Buffer (мой новый метод)

Ни B262, ни B263, ни B264, ни B265, ни B266 не решили первопричину, которую сам B262-аудит назвал верно: `action diversity → consequence diversity → identifiable causal model`. Каждый последующий проход измерял эту проблему точнее, но не производил больше **реального разнообразия** самого опыта.

Метод: отдельный, явно обозначенный «экспериментальный режим» (включается только при достаточном `cognitiveBudget01` и явном согласии пользователя — никогда тайно), в котором организм сам генерирует короткие текстовые мини-сценарии («что если бы я ответила иначе», «что если бы цель была другой») и целенаправленно перебирает наименее опробованные из безопасного набора действий/реакций именно в них — не в обычном разговоре с вами, чтобы не портить качество живого общения. Результат — разнообразные пары (действие → исход) — идут напрямую в `B263RealActionCausality` / `B264CausalPolicyLearning` как дополнительные обучающие данные. Технически это использует уже существующую инфраструктуру reflection/dream-цикла — не новый физический орган, а новый **режим работы** существующих органов.

Критерий готовности: `causalGain01` / `behavioralGain01` в последующих B26x-тестах должны **измеримо вырасти** относительно текущих (почти нулевых) значений именно после добавления этого буфера — это прямая, проверяемая гипотеза, не голое заявление.

4.3 Явная развилка: self-model/agency/motivation (из `ORIGINAL` B263-265) vs regime-shift (из фактического B267)

Оба — законные следующие шаги. По вашему правилу (не жертвовать многим ради малого выигрыша в другом месте) — **делать оба, но не одновременно в одном проходе**: B267 = regime-shift/adaptation (уже спроектировано и правильно приоритезировано, так как без этого continual learning бессмысленен). **B268 = вернуться к self-model/agency/motivation** из `ORIGINAL`-плана, которые были отложены, а не отменены — не забудьте про

них, иначе то самое «уходим на новый фронт, не закрыв текущий» повторится уже на уровне самих больших планов.

---

5. Полная цепочка до конца — большими проходами (продолжение BUILD 1–20 вашего же плана)

Ваш `ORIGINAL`-документ уже дал верный список BUILD 1–20. Я не меняю номера и содержание — я подтверждаю его как правильный (это редкий случай, когда ваш собственный план не нуждается в переделке, только в дисциплине исполнения) и добавляю конкретику по тому, что фактически уже закрыто, что нет, и что добавить от себя.

BUILD	Что это	Статус на архиве B266	Ч
1. Canonical neural state	Единое обучаемое состояние	✅ B259 сделал	-
2. Trainable parameter registry	Реестр обучаемых параметров	Частично (веса per-horizon в B262)	Я с в с D и с к п т а N
3. Eligibility traces	Причинные «следы допустимости»	Частично (Causal Eligibility Ledger предложен в `ORIGINAL`, не проверено, реализован ли)	П ч E l с п б
4. Real local plasticity	Настоящая локальная пластичность	⚠️ Слабое место (`ORIGINAL` явно называет B251 как «credit score, не полноценный learning»)	Т с Д с

BUILD	Что это	Статус на архиве B266	
5. Recurrent shared latent	Общее рекуррентное состояние	✅ B259/B261	
6. Action-conditioned prediction	Предсказание с учётом действия	✅ B261-B262	
7. Real execution consequences	Реальные последствия исполнения	⚠️ B263 сделал первый шаг, но данные всё ещё в основном из controlled/synthetic среды	
8. Causal credit	Причинное распределение заслуги	✅ B263-B264	
9. Memory interaction	Взаимодействие с памятью	✅ B260, углубить в B268+	
10. Workspace competition	Конкуренция за внимание	Есть с более ранних passes (P7 network, ignition/inhibition) — не переоткрывать	
11. Self/world embeddings	Представления себя/мира	Частично (P31FunctionalConsciousness, но не как learned dynamics)	
12. Agency posterior	Вероятностная модель собственной агентности	Не сделано явно	

BUILD	Что это	Статус на архиве B266	Ч
13. Value/motivation model	Модель ценностей/мотивации	Частично (`AutonomousGoalSystem` -подобное существует в более ранних P-модулях, не интегрировано с B259-266 causal chain)	
14. Sleep/replay consolidation	Консолидация во сне	Частично (MicroDreamEngine упомянут в KARTA, реальная интеграция с B259-267 не проверена)	
15. Structural plasticity	Структурная пластичность (не только веса, но архитектура)	`SandboxedSelfRewriteEngine` (B253) — safety-gate, не полноценный движок	
16. Transfer benchmark	Перенос на новые условия	✅ B266 (сделан раньше срока — хороший знак)	
17. Lesion matrix	Полная матрица lesion/sham/partial/recovery для каждой системы	Есть отдельные lesion-функции (P31, B262 world-model lesion), но не единая систематическая матрица по всем системам	
18. Longitudinal benchmark	Долговременный бенчмарк (недели/месяцы)	Есть инфраструктура (`LongitudinalOrganismEngine` и т.д.), реальный многодневный	

BUILD	Что это	Статус на архиве B266	Ч
		прогон не подтверждён мной лично	
19. Adversarial consciousness battery	Состязательная проверка гипотез о сознании	Частично (M1-M10 из старого архива, adversarial упоминается, полная батарея не проверена)	
20. Mobile embodied deployment	Реальное развёртывание на телефоне с полным циклом	⚠️ Инфраструктура есть (zero-deps, Termux-скрипты, лёгкий UI), но нет подтверждённого прогона на физическом Android	

---

6. Что нужно для полной реализации проекта — прямой ответ

Вы сказали, что запускаете пока на телефоне. Вот что конкретно нужно, без розовых очков:

1. **Реальный прогон на физическом Android-устройстве, не только в контейнере/на ПК.** Это единственный пункт, который явно и неоднократно помечен как невыполненный самим проектом («Android device gate: recommended-before-long-running-Android-use», «no Android device gate available»). Хорошая новость: поскольку эта ветка имеет **0 npm-зависимостей**, риск OOM при установке, который был главной угрозой для предыдущего архива (v99.80), здесь практически снят — можно запускать `node --experimental-strip-types src/server/server.mjs` (или через `scripts/termux/start.sh`) без сборки. Это стоит проверить в первую очередь, до продолжения научной части — потому что если что-то в Termux всё же ломается (другая версия Node, другие лимиты памяти на конкретном телефоне), лучше узнать это сейчас, а не после ещё 10 больших проходов.

2. **Довести `autoRun` (Кирпич 0) до реальной работы** — без этого «автономность» остаётся утверждением, а не свойством.
3. **Закрыть BUILD 4 (real local plasticity) и BUILD 11-13 (self/agency/value как learned dynamics), которые `ORIGINAL`-план отложил, а исполнение B259-266 пока не вернулось к ним** — иначе кривая прогресса продолжит расти вширь (breadth) быстрее, чем вглубь (depth), что и есть диагностированное застревание.
4. **Прогнать `audit:all` до конца** (не останавливаясь на первой ошибке, как сделал я из-за бюджета времени) — чтобы узнать, есть ли ещё скрытые регрессии в старых P-модулях, кроме найденного `p15.5`.
5. **Явно решить судьбу README** как источника правды (раздел 2.2 аудит-документа) — мелкая, но реальная работа по гигиене.
6. **В какой-то момент — переподключить эту ветку к решению исходной задачи**: у вас есть *два* активных направления (телефон-приложение `v96work` /v99.80 с настоящим UI и Live2D в браузере, и эта исследовательская ветка `35.6.1` с более глубокой когнитивной наукой и уже своим, более простым UI). В какой-то момент придётся явно решить: эта ветка **заменяет** телефон-приложение, или её когнитивное ядро (`src/organism`) будет **перенесено/подключено** в существующее приложение. Сейчас это не решено ни в одном документе, который я видел — я рекомендую явно зафиксировать это решение в следующем большом проходе, потому что дальнейшая работа над обеими ветками параллельно рискует создать именно ту фрагментацию, о которой ваш собственный `BRAIN_MASTER_PLAN_AND_AUDIT` предупреждает в разделе «Архитектурная опасность».

---

7. Как продолжать в новом чате

1. Загрузите этот документ **вместе** с `AUDIT_CLAUDE_B266_35_6_1_RU.md` и, если возможно, свежий архив проекта (состояние могло измениться после B266).
2. Скажите новому чату, на каком BUILD/большом проходе вы сейчас находитесь (после B267? B268?).
3. Попросите новый чат **сначала** лично запустить `npm run test:p15.5` и `npm run audit:all` — не доверять этому документу на слово о том, чинён ли `autoRun` к этому моменту.
4. Если решение из раздела 6.6 (объединение веток) уже принято — явно это укажите, чтобы план не предполагал несуществующую развилку.